



CUNEF

MÁSTER UNIVERSITARIO EN CIENCIA DE DATOS

TÉCNICAS DE PREDICCIÓN: SERIES TEMPORALES

BMW y Volkswagen

Aitor Larrinoa Rementería

Noviembre 2021

Índice

1. Introducción	3
2. Conclusiones	4
3. Datos	5
4. Modelo VAR	5
4.1. Predicción para octubre de 2021	6
5. Modelo GARCH	7
5.1. Predicción para el mes de noviembre de 2020	8

1. Introducción

En este informe, se podrá ver la realización de la tercera práctica de la asignatura *Técnicas de predicción: series temporales*.

El trabajo constará de ir respondiendo a las preguntas planteadas en dicha práctica. El trabajo está estructurado en tres grandes bloques. El primero será relativo al bloque de introducción y conclusiones. El segundo constará de la creación y conclusiones de un modelo VAR y, finalmente, el último de los bloques será relativo a la creación de un modelo GARCH.

Se tratará de dar una breve introducción a los modelos sin entrar mucho en detalle en los mismos para, de esa manera, facilitar la lectura.

Durante los bloques segundo y tercero, se irán resolviendo las preguntas planteadas en esta práctica, a medida que se vayan obteniendo resultados y más información.

Por otro lado, por falta de tiempo, no se va a poder plantear el algoritmo de trading a partir del modelo GARCH.

2. Conclusiones

El modelo VAR analizado para Volkswagen y BMW ha sido un modelo realmente inadecuado. Esto se debe a que no existe relación de causalidad entre los precios de los activos de ambas empresas. Además, los coeficientes obtenidos para dicho modelo, podemos asegurar, que son estadísticamente 0, por lo que no tiene sentido alguno el haber planteado dicho modelo.

Por otro lado, el modelo GARCH estudiado, a diferencia del modelo VAR, predice de una manera correcta a corto plazo. Sin embargo, a medida que el horizonte de predicción se amplía, las predicciones pierden precisión y dejan de ser fiables.

En definitiva, si nuestro objetivo es predecir días en un mes, podemos hacer uso del modelo GARCH, pero si nuestro objetivo es predecir a largo plazo, este modelo no es el más adecuado. En cuanto al modelo VAR, ya hemos podido ver en las predicciones que no podemos hacer uso de él.

3. Datos

En esta ocasión, trabajaremos con los precios de las acciones de las empresas alemanas *BMW* y *Volkswagen*. Los datos serán descargados desde YahooFinance. El rango de fechas que consideraremos irá variando en función de las diferentes conclusiones que queramos ir sacando.

Aunque la descarga de los activos de ambas empresas nos da información sobre el precio más alto diario, el más bajo, la fecha, el precio de apertura, el de cierre y el precio de cierre ajustado, a nosotros únicamente nos interesarán los datos del precio de cierre ajustado y fecha.

- **Fecha:** Fecha de cada dato.
- **Adjusted Close Price:** Precio de cierre después de los ajustes y distribución de dividendos.

Después de obtener los datos diarios, dado que trabajaremos con datos mensuales, reorganizaremos los datos pasándolos a mensuales y quedándonos con el último dato del mes. Mostremos ahora una gráfica de ambas series temporales para ver gráficamente los datos. En esta ocasión el gráfico contendrá datos entre las fechas de enero de 2009 y octubre de 2020.




Figura 1: Gráfica de las series temporales

La gráfica nos muestra momentos importantes en el sector automovilístico. Por un lado, observamos el famoso *dieseldgate*¹ en septiembre de 2015 en las acciones de la empresa Volkswagen. Por otro lado, la inconfundible época de COVID en marzo de 2020, la cual afectó a ambas empresas.

4. Modelo VAR

En diferencia con los anteriores modelos, los modelos VAR son multidireccionales. En anteriores casos, los modelos estudiados únicamente tienen una variable respuesta y sus corres-

¹En septiembre de 2015 salió a la luz que Volkswagen había instalado ilegalmente un software para alterar los resultados de los controles técnicos de emisiones contaminantes en 11 millones de automóviles con motor diésel, vendidos entre 2009 y 2015

pondientes covariables, pero, en este caso, también permitiremos que las covariables ejerzan influencia sobre la variable respuesta.

Para poder hacer uso del modelo VAR, es necesario que las series con las que estemos trabajando sean series estacionarias y, en nuestro caso, vemos claramente que ninguna de las dos series lo es. Luego, para convertir las series a estacionarias, aplicaremos la tasa de variación logarítmica a ambas. Después de hacer esto, comprobamos mediante el *test de adfuller*² si las series transformadas mediante la tasa de variación logarítmica son estacionarias o no. Dado que el p-valor que obtenemos es del orden de 10^{-22} y 10^{-16} para Volkswagen y BMW respectivamente, podemos asegurar que aplicando a las series la tasa de variación logarítmica, obtenemos una serie estacionaria.

Lo primero y más importante que debemos hacer es determinar el orden del modelo VAR. Para ello, lo que haremos será considerar 15 retardos y calcular el *AIC*³ del modelo para cada retardo. Esto nos servirá para detectar cuál es el retardo con menor AIC y, de esa forma, obtendremos el orden del VAR deseado. El resultado es que el menor AIC se da con un retardo. Luego, construiremos un modelo VAR de orden 1

Una vez tenemos el orden deseado, procedemos a estimar el modelo. Cuando lo estimamos, nos damos cuenta que los coeficientes de nuestras ecuaciones del modelo tienen un p-valor mayor que 0.05. Dicho de otro modo, no se puede rechazar la hipótesis de que los coeficientes sean diferentes de 0, por tanto, tenemos que los coeficientes no son significativos. Por ello, nuestro modelo VAR no tienen ningún sentido y no merece la pena seguir con él ni sacar predicciones.

Aun así, se nos pide estimar el modelo VAR, y, es por ello que mostramos la tabla de coeficientes resultante a continuación:

	Coeficiente	Prob
L1. BMW	0,090698	0,383
L1. VOW	-0,100251	0,194
L1.BMW	-0,070201	0,609
L1. VOW	0,037208	0,716

Cuadro 1: Coeficientes del modelo VAR

Es importante recalcar que el modelo VAR ha sido calculado sin constante. Los primeros tres valores son los coeficientes relativos a la ecuación de BMW y los segundos tres valores son los relativos a la ecuación de VOW.

Finalmente, atendiendo al test de causalidad de Granger, podemos asegurar que **no hay seguidor ni líder entre ninguno de estos dos activos**.

4.1. Predicción para octubre de 2021

Las predicciones del modelo VAR para el mes de octubre del año 2021 se pueden ver en la siguiente tabla:

²El test de adfuller es un test estadístico que determina si una serie es estacionaria o no

³El criterio de información de Akaike (AIC) es una medida de la calidad relativa de un modelo estadístico

	Valor real	Predicción
BMW	87,24	63,67
VOW	63,67	130,633

Cuadro 2: Comparación realidad y predicción del modelo VAR

Como era de esperar, la diferencia entre el valor real y la predicción es bastante grande. **Luego, estas predicciones no son nada buenas.**

5. Modelo GARCH

el modelo GARCH sirve para encontrar la volatilidad promedio a medio plazo mediante una autorregresión que depende de la suma de perturbaciones rezagadas y de la suma de varianzas rezagadas.

El modelo GARCH que hemos estimado es relativo a la rentabilidad y volatilidad de BMW. Lo primero que se deberá tener en cuenta es que la muestra que analizaremos estará comprendida entre 1996 y 2020, esto es, estimaremos el modelo GARCH de BMW con toda la muestra disponible hasta el 31/10/2020.

Una vez tenemos los datos diarios de la muestra mencionada anteriormente, calculamos por un lado los rendimientos y, después la volatilidad (el cuadrado de las rentabilidades). El resultado gráfico de los precios, rentabilidad y volatilidad se ve a continuación:




Figura 2: Gráfica de precio, rentabilidad y volatilidad de BMW

Claramente podemos observar los diferentes cluster que nos muestra la volatilidad en los periodos más inciertos para BMW. Viendo los resultados, podemos asegurar que la volatilidad de las rentabilidades de BMW no es estacionaria, luego, tiene sentido plantear un modelo GARCH con el fin de poder analizar dicha volatilidad.

Vamos a plantear entonces un modelo GARCH(1,1). Lo haremos ajustándonos a una T de student ya que el modelo se ajusta mejor a dicha distribución que a una normal.

Los modelos para la media y volatilidad obtenidos son los siguientes:

	Valor	Probabilidad
Constante	0,0372	$5,632e - 02$
Log_ret[15]	-0,0175	0,138

Cuadro 3: Coeficientes del modelo GARCH para la media

	Valor	Probabilidad
omega	0,0177	$2,748e^{-03}$
α_1	0,0535	$4,388e^{-14}$
β_1	0,9447	0,000

Cuadro 4: Coeficientes del modelo GARCH para la volatilidad

Podemos observar que la mayoría de los coeficientes son significativos, lo cual es buena señal, puesto a que estadísticamente, tenemos ecuación a diferencia con el modelo VAR. Por otro lado, atendiendo al test de Box-Ljung, vemos que los residuos no están autocorrelacionados.

5.1. Predicción para el mes de noviembre de 2020

Haciendo uso del modelo GARCH, mostramos en la siguiente tabla el valor real, el valor predicho y su respectivo error.

Fecha	Predicción	Valor real	Error
2020-11-02	57,541202	57,541189	0,577444
2020-11-03	59,491494	59,491502	0,350801
2020-11-04	58,422032	58,422028	1,043308
2020-11-05	61,321679	61,321706	0,225108
2020-11-06	56,624326	56,624305	4,454652
2020-11-09	57,351679	57,351668	7,183687
2020-11-10	57,436436	57,436427	8,903516

Cuadro 5: Comparación realidad y predicción del modelo GARCH

El error ha sido calculado como el valor absoluto de la diferencia del valor real y el valor predicho.

Luego, después de verlo y analizarlo, parece que las predicciones del modelo GARCH son realmente buenas para los primeros días, aunque, a medida que avanzan los días, las predicciones se vuelven cada vez menos precisas. Esto último es totalmente lógico ya que cuantos más días pasen el riesgo incrementa y con ello la volatilidad.

El motivo de no mostrar toda la tabla del mes de noviembre se debe a que ya hemos observado que el error aumenta a medida que el tiempo pasa.